공공데이터 기반 구직자용 웹 서비스

다닐만한가

"이 회사, 다닐 만한가?"에
공공데이터 숫자로 답합니다

4인 팀 · 2026-10-02 ~ 10-21

팀장 김태완 데이터 파이프라인

팀원 서승범 프론트엔드

팀원 양준석 DB와 SQL

팀원 최진영 백엔드와 운영

web-chi-flax-46.vercel.app

구직자가 보는 정보는 회사가 쓴 글과 익명 후기뿐

지금 보는 것

채용공고

회사가 직접 쓴 글

익명 리뷰

개인의 경험 한 사람분

이미 공개된 공식 데이터

국민연금 가입 사업장

가입자 · 입사 · 퇴사 · 고지금액, 매월

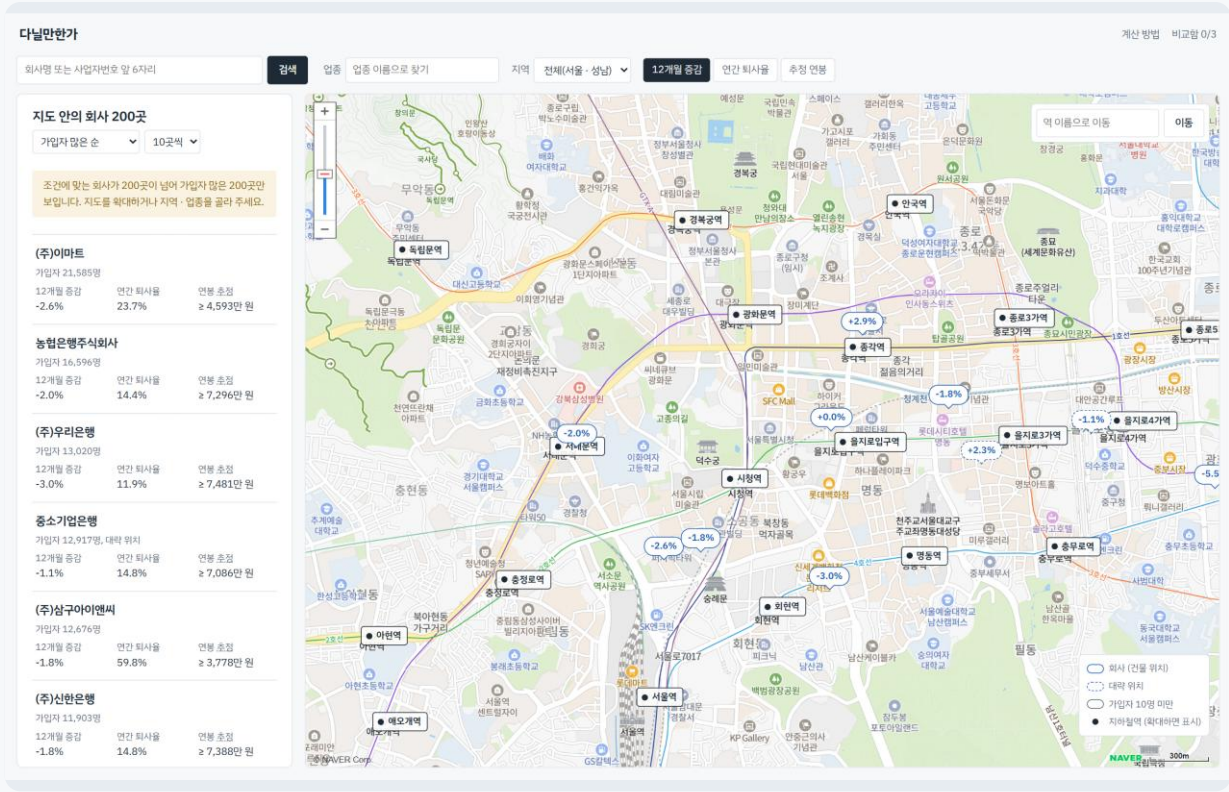
OpenDART · 서울시 전월세 실거래

재무제표, 신고된 임대 계약

그런데 그대로는 못 씁니다. 한 달치 스냅샷, 사업장 단위, 출처 사이 공통 키 없음, 건물번호 없는 주소, 지번 단위 실거래

주요 사용자 신입 · 이직 구직자, 지방에서 서울 · 판교로 오는 구직자. 성장하는지, 자주 떠나는지, 근처에서 살 수 있는지 궁금한 사람

기능 요구사항과 화면: 지도 위에 회사와 주거비를



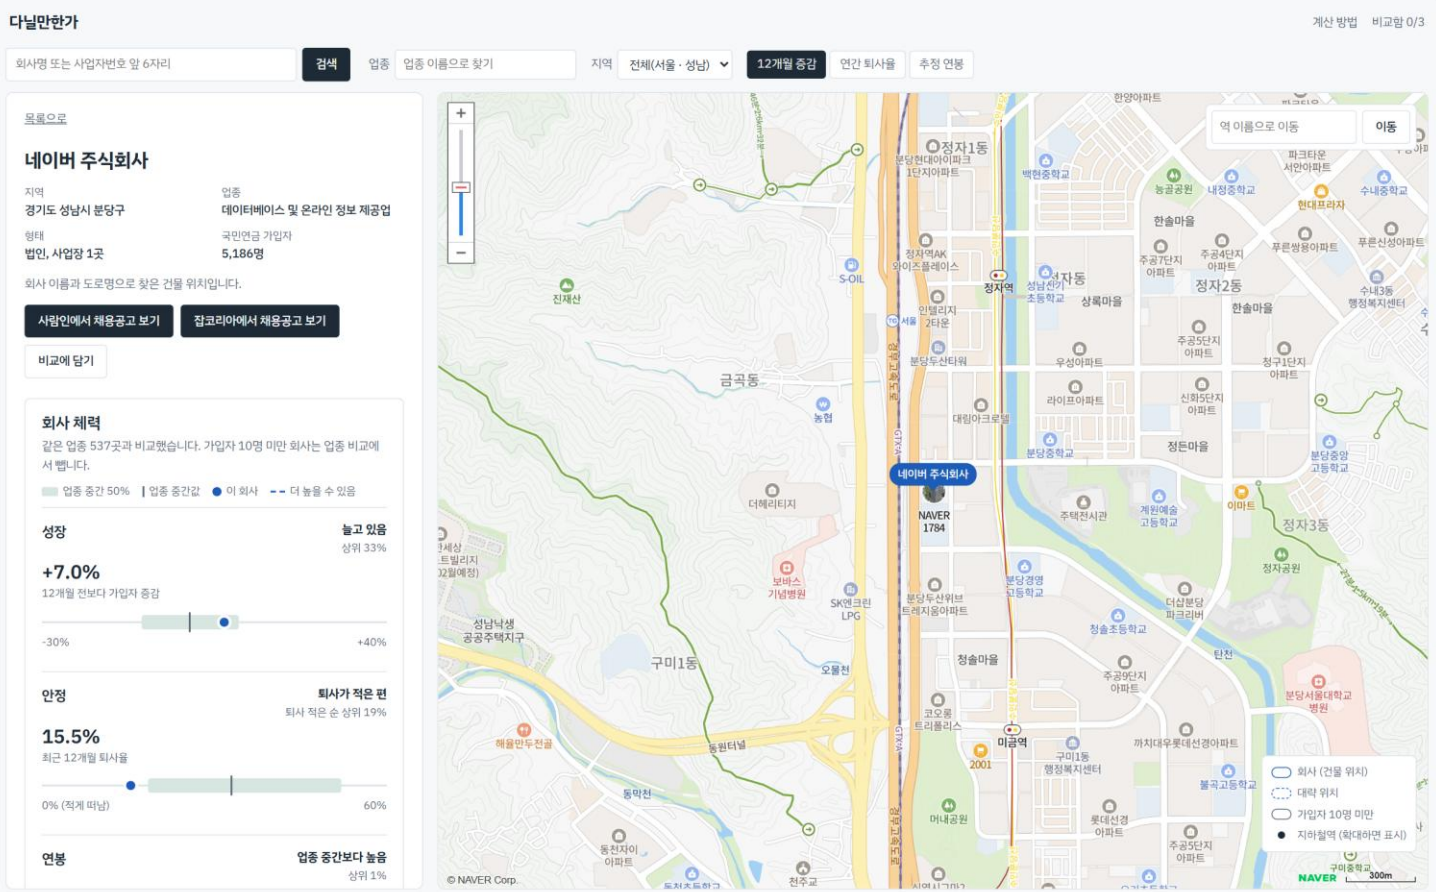
화면 설계: 위쪽 막대 · 지도는 고정, 왼쪽 패널만 목록 → 상세 → 비교로 바뀜

기능	요구사항
검색	회사명 · 사업자번호 · 업종
회사 상세	증감 · 퇴사율 · 연봉 · 백분위
지도	지도 안 회사 핀 · 목록 · 역
비교	회사 · 역 최대 3곳 나란히
주거비	근처 역 원룸 시세 · 부담률
채용	사람인 · 잡코리아 검색 바로가기
투명성	기준월 · 출처 · 추정 한계

P0 모두 구현

기능 요구사항 61개: 구현 50 · 대체 4 · 하지 않음 7

회사 상세: 회사 체력을 세 줄로 봅니다



성장

12개월 가입자 증감과 업종 안 위치

+7.0%, 업종 상위 33%

안정

연간 퇴사율, 업종 중간 50% 띠와 비교

15.5%, 퇴사 적은 순 상위 19%

연봉

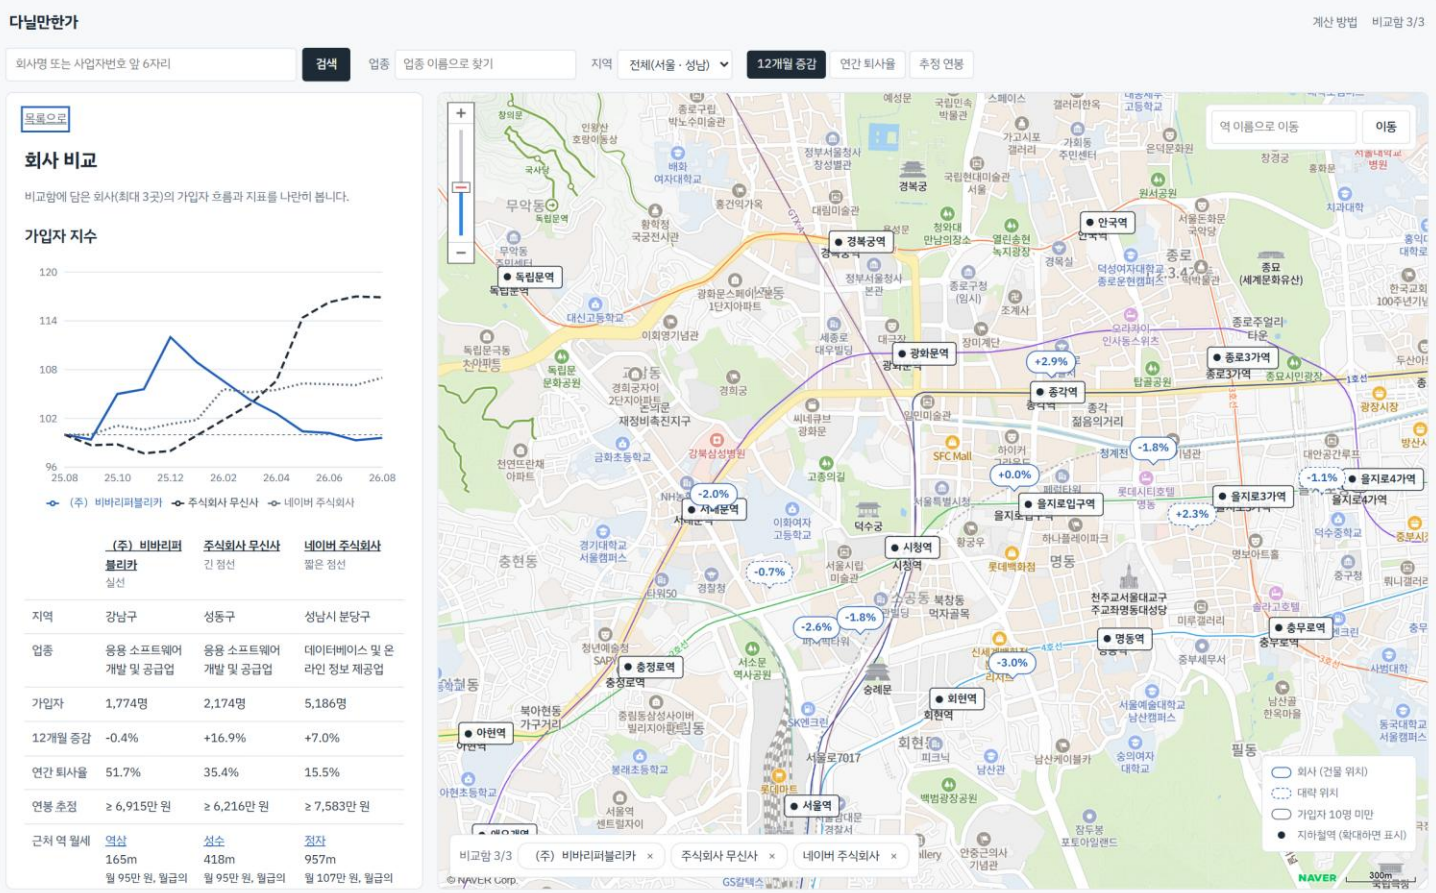
국민연금 고지금액으로 역산한 하한

≥ 7,583만 원

바로가기

사람인 · 잡코리아 채용 검색, 비교에 담기

회사 비교: 후보 3곳을 나란히 봅니다



가입자 지수

첫 달을 100으로 맞춘 13개월 흐름. 회사는 선 모양(실선 · 긴 점선 · 짧은 점선)으로 구분

지표 표

지역 · 업종 · 가입자 · 12개월 증감 · 퇴사율 · 연봉

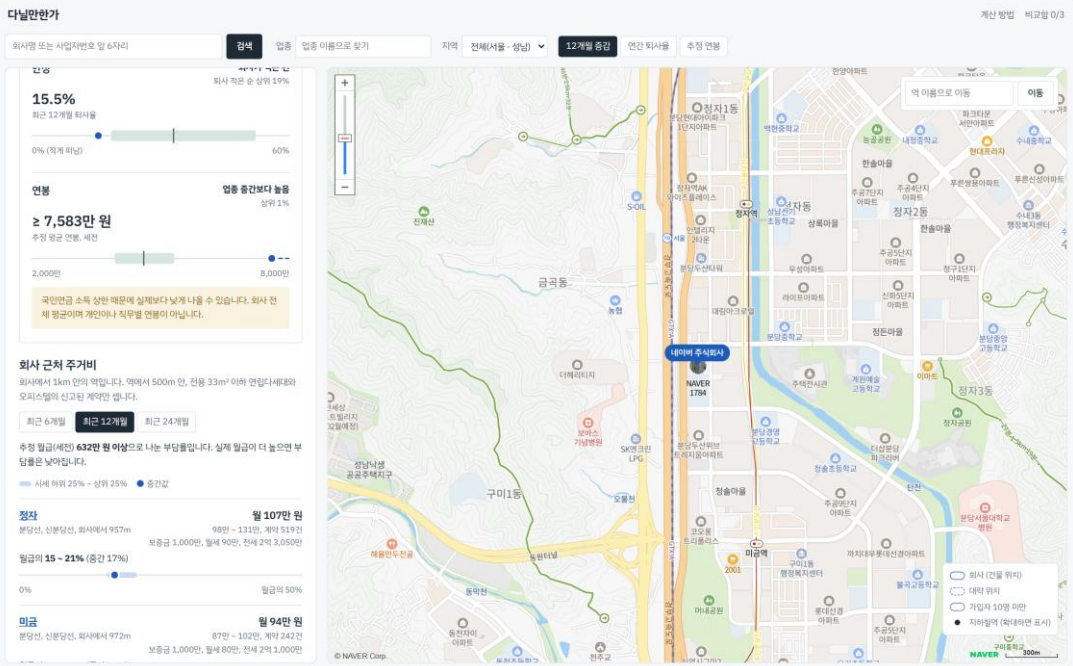
근처 역 월세

가장 가까운 역의 원룸 시세와 월급 대비 비율

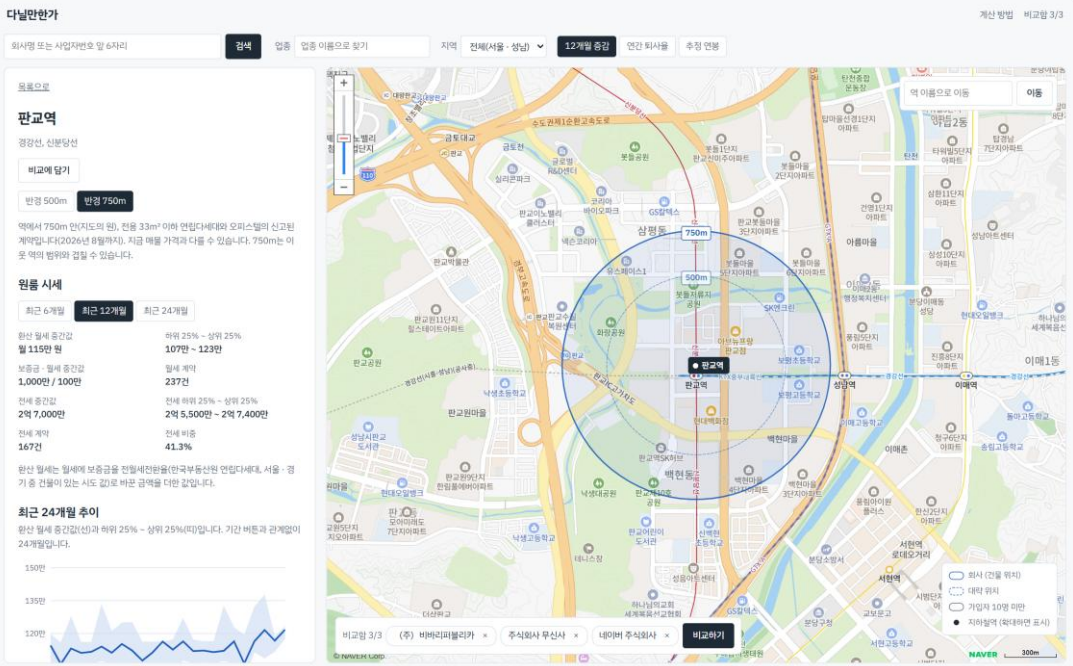
담기 · 공유

아래 비교함에 최대 3곳, 주소(?ids=)로 같은 화면 공유. 역도 3곳까지 비교

근처 주거비: 회사 옆 역의 원룸 시세



회사 상세 아래: 1km 안 역 최대 3곳과 월급 대비 부담률
네이버 → 정자역 957m, 월 107만 원, 월급의 15 ~ 21%



역 시세 화면: 반경 500 · 750m, 6 · 12 · 24개월, 24개월 추이
판교역 750m 12개월 → 월 115만 원(237건)

원룸 = 전용 33㎡ 이하 연립다세대 · 오피스텔 · 환산 월세 = 월세 + 보증금 × 전월세전환율 ÷ 12 · 계약 20건 미만이면 24개월로 넓힘

다닐만한가 · 6 / 17 · 배포 사이트 화면(2026-10-20), 요구사항 FR-HOUS-01 ~ 07

전체 구성: 로컬에서 적재하고 배포는 읽기만



기술 스택: 통계는 SQL로, 화면은 지도 위에

수집 · 정제

Python 3.12 · httpx · pandas

공공데이터 CSV · API, CP949 처리, 재시도 · 하루 호출 한도

매칭 · 좌표

rapidfuzz · pyproj

회사명 유사도 85점 이상, 주소정보누리집 좌표(UTM-K → 경위도)만 저장

DB

MariaDB 11.4 · Alembic

윈도 함수 · PERCENTILE_CONT · 공간 인덱스 · 월 월 파티션, 마이그레이션 11개

API

FastAPI · Pydantic v2 · SQLAlchemy 2.0 2.0

읽기 전용, sql/ 파일을 그대로 실행, 응답 캐시 · ETag

웹

Next.js 15 · React 19 · Recharts · 네이버 지버 지도

지도 + 패널, API 타입은 OpenAPI에서 생성

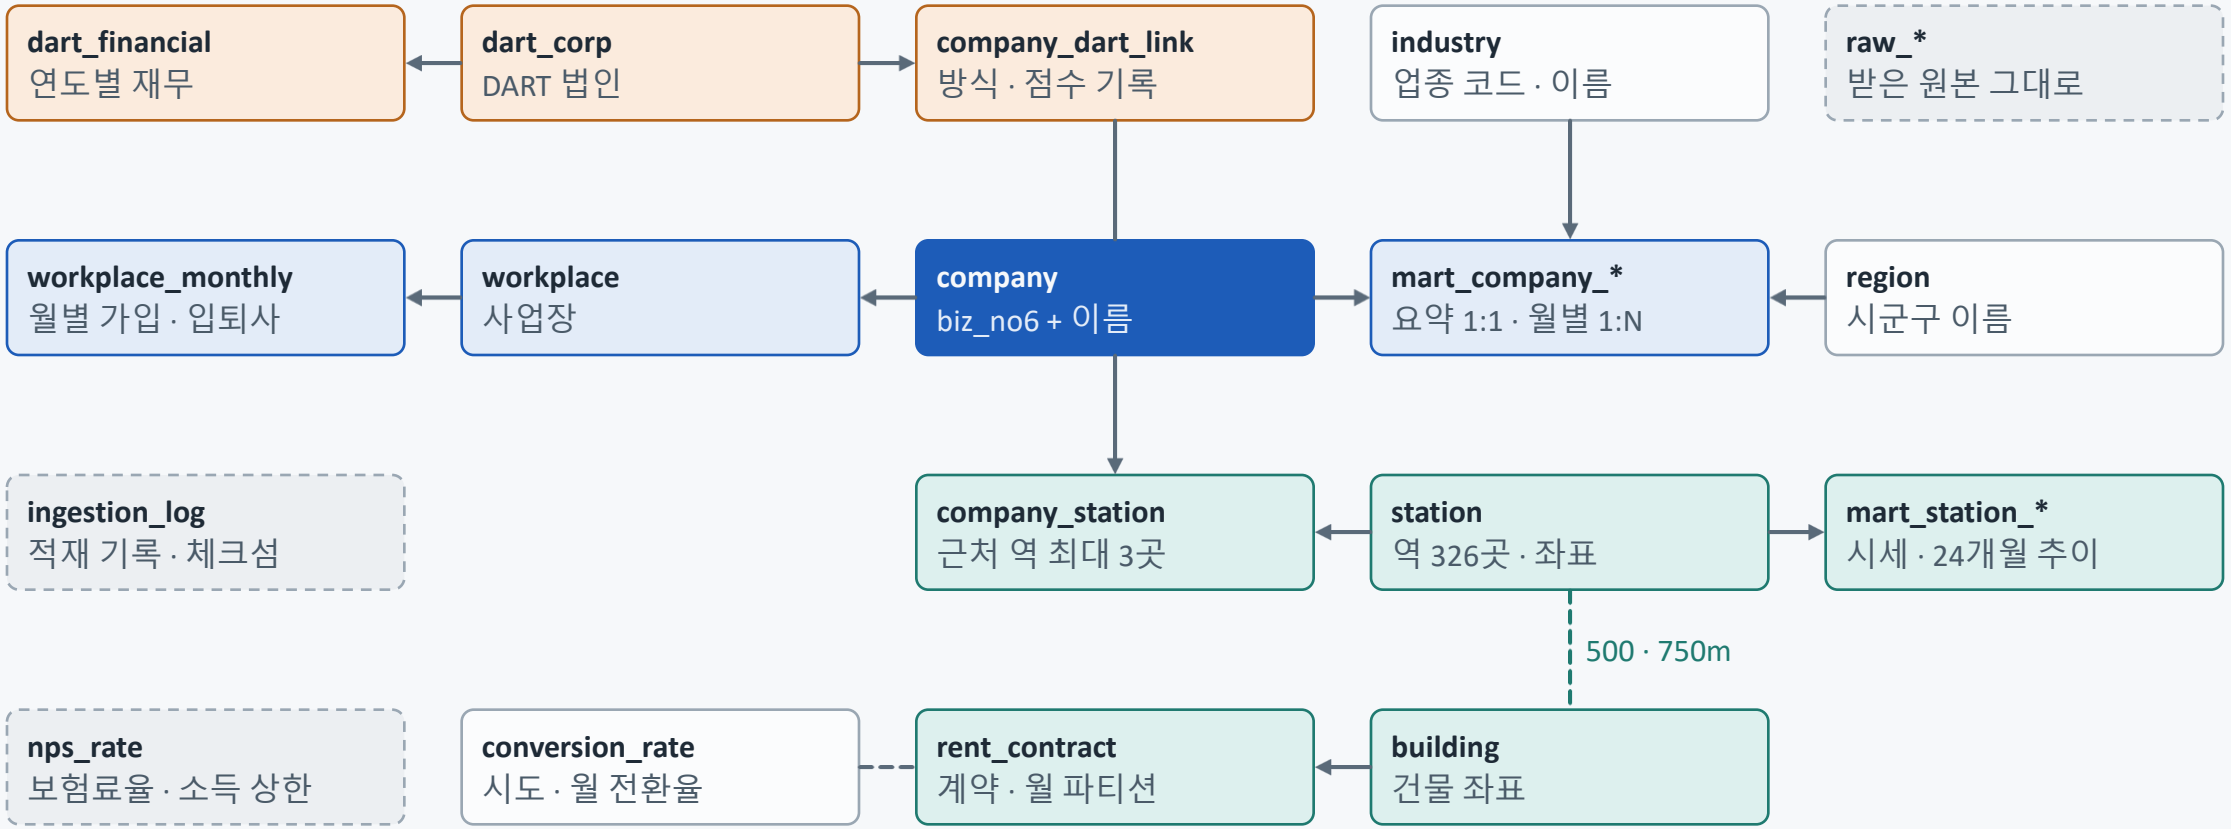
품질 · 배포

pytest · Playwright · GitHub Actions

Railway(API · DB) + Vercel(웹), ruff · locust · CSP CSP

쓰지 않은 것: LLM · 임베딩(통계는 모두 SQL), 채용 사이트 크롤링, 배포 서버의 적재 cron(로컬에서 검증 후 반영)

ERD: 회사를 가운데 두고 DART · 역이 이어집니다



화살표 1 → N · 선만 1 : 1 · 점선은 키 없이 좌표 · 월로 잇는 관계 · 회사 · DART · 역 · 전월세 · 회색은 조회 · 운영 표

API 흐름: 요청은 mart까지, 응답엔 as_of · flags



위는 요청, 아래는 응답입니다. 요청 때 집계하지 않고 미리 만든 mart 행만 읽어, **상세 8ms · 검색 6ms**(로컬 부하 p95)입니다.

공공데이터를 회사 · 위치로 잇습니다

데이터 5종

국민연금 13개월, 회사 137,129곳

OpenDART 법인 · 재무

전월세 서울시 · 국토부, 계약 47만 건

역 430행 → 326곳

주소정보누리집 건물 · 출입구 좌표

CP949 · 중복 행 합산 · 열 형식 통일 · 신고 지연 처리

회사 매칭

1 정확 사업자번호 6자리 + 정규화 이름(16,156 (16,156건)

2 유사 같은 6자리 안 유사도 85점 이상(161건)

3 그 외 잇지 않음, 방식 · 점수 기록

79.3%

가입자 1,000명 이상 회사 DART 연결

회사 좌표

건물번호 없는 주소라 4단계: DART 본사 → 상호 검색 → 도로 중심 → 동 중심

건물 13,030 · 도로 122,334 · 동 1,764곳

16초

API 2.6만 회(약 4.5시간) 대신 주소 파일로 계산

좌표는 이용 조건상 저장이 허용된 주소정보누리집 것만 씁니다. 대략 위치는 지도에 점선 핀으로 구분합니다.

핵심 SQL: 통계는 DB 안에서 미리 계산합니다

① 빠진 달은 비워 둠

한 달 빠지면 LAG가 두 달 전 값을 가져와 퇴사율이 틀립니다

```
CASE WHEN LAG(snapshot_ym)
OVER w = PERIOD_ADD(
snapshot_ym, -1)
THEN lost / NULLIF(
LAG(members) OVER w, 0)
END AS quit_rate
```

직전 달이 아니면 NULL

② 업종 백분위

60.7%가 10명 미만. 한 명만 나가도 분포가 흔들립니다

```
PERCENT_RANK() OVER (
PARTITION BY
industry_code,
quit_rate_12m IS NULL
OR excluded
ORDER BY quit_rate_12m)
```

표본 부족 · 미분류는 NULL

③ 역세권 공간 조인

윈도 함수와 섞으면 공간 인덱스를 안 써서 5분

```
INSERT INTO
station_building
SELECT st.station_id, …
FROM station st
STRAIGHT_JOIN building b
ON MBRContains(ST_Buffer(
st.pt, 0.009), b.pt)
```

쌍 먼저: 320초 → 0.9초

시연

실제 서비스 화면으로 아래 세 가지를 차례로 시연합니다

01

메인 화면

지도에서 회사 핀과 목록,
지하철역을 함께 보고 핀 지표를
바꿔 봅니다

02

회사 상세

회사 하나를 열어 성장 · 안정 ·
연봉과 근처 역 주거비를
확인합니다

03

비교

후보 회사 3곳을 담아 가입자 지수
그래프와 지표 표로 나란히 봅니다

부딪힌 문제는 모두 기록하고 재발을 막았습니다

주제	무엇이 문제였나	어떻게 풀었나
생성 컬럼(1901)	MariaDB는 CHAR 원본의 생성 컬럼을 거부	원본을 VARCHAR로, 생성 컬럼 + 일반 인덱스
공간 인덱스(TS-025)	윈도 함수 안 공간 조인이 인덱스를 안 씀	쌍을 먼저 만들기, 좌표 범위로 먼저 거르기
임시 테이블(TS-028)	750m를 더하자 16MB를 넘어 디스크로, 10분	이 연결의 한도를 256MB로, 다시 0.9초
대표 사업장 중복	모든 사업장으로 회사-역 순위 → 같은 역이 겹쳐 1순위가 사라짐	회사마다 대표 좌표 하나로만 순위
좌표 API(TS-022)	몰아 부르면 오류를 정상 응답으로 줘 실패로 캐시됨	일시 오류는 캐시 안 함 → 결국 주소 파일로 16초
전각 괄호(TS-016)	“ ㈜” 가 정규화되지 않아 같은 회사가 둘로	NFKC 정규화 뒤 다시 만듦

문제마다 증상 · 원인 · 해결 · 재발 방지를 남겼습니다: troubleshooting.md TS-001 ~ 034

프로젝트 성과: 숫자로 확인했습니다

±6%

인원 정확도

DART 직원 수와 대조(대기업 5곳)

8 · 6ms

상세 · 검색 응답 p95

목표 300 · 500ms, 로컬 부하 20명

53 → 81

상세 화면 Lighthouse 성능

한글 글꼴 2.6MB → 0.3MB

137,129

서울 · 성남 회사

역 326곳 · 전월세 계약 47만 건

234 · 15

pytest · 화면 테스트

PR마다 CI, 키 없이 샘플로

120+

병합한 PR

결정 기록 10 · 문제 기록 34

연봉은 국민연금 소득 상한 때문에 늘 낮게 나와, 화면에는 "≥ 하한 추정"으로만 씁니다.

한계를 숨기지 않았고, 다음 할 일도 정했습니다

한계

- 추정 연봉은 회사 평균의 하한. 개인 · 직무별이 아님
- 서울 · 성남 사업장만, 공개 기준(법인 3인 · 개인 10인) 미만은 없음
- 회사 위치 약 1.3만 곳만 건물 단위, 나머지는 도로 · 동 중심
- 채용공고는 모으지 않고 사람인 · 잡코리아로 연결

다음

- 월 갱신을 명령 하나로(pipeline.monthly)
- 경기 다른 시로 확장(같은 방식)
- API 서버를 아시아 리전으로(응답 약 70ms 단축 예상)

공공데이터는 “있다”와 “쓸 수 있다” 사이가 멉니다. 그 사이를 SQL과 검증 숫자로 메웠습니다.

7. 질의응답 및 추가 시연

질문 받겠습니다

추가 시연할 수 있는 것

- 역 3곳 비교 · 24개월 시세 추이
- 계산 방법 페이지(계산식 · 한계 · 기준월)
- 회사 재무(DART) · 이름 기준 연결 표시
- API 문서 화면(/docs)

web-chi-flax-46.vercel.app